

비전 언어 모델(VLM) 기반 계층적 비디오 분석을 통한 멀티트랙 사운드 메타데이터 생성 파이프라인 개발*

박광웅^{1,ο}, 조영우², 차수환², 최재원², 장두성^{3,**}

¹서강대학교 경영학과, ²서강대학교 컴퓨터공학과, ³서강대학교 인공지능학과

zx1017@sogang.ac.kr, owq0522@gmail.com, dndoehrk11@gmail.com, cjw9770@gmail.com, dschang@sogang.ac.kr

Automatic Multi-Track Sound Metadata Generation via Hierarchical Video Analysis Using Vision Language Models

Gwang-Woong Park^{1,ο}, Young-Woo Cho², Suhwan Tcha², Jaewon Choi², Du-Seong Chang^{3,**}
Sogang University

요 약

최근 생성형 AI 기술의 발전이 오디오 생성 분야로 빠르게 확장되며 사운드 디자인에 활용되고 있다. 기존 연구는 싱글트랙 오디오를 생성하는 데 그쳐 현업에서 요구되는 멀티트랙 사운드 엔지니어링 워크플로우와 괴리가 있다. 특히 영상 내 여러 사운드를 개별 트랙으로 분리하고 컷 전환에 걸친 동일 사운드를 일관되게 추적하는 구조적 표현이 부재하다는 점이 핵심 과제로 남아 있다. 본 연구에서는 사운드 소스 레지스트리 구축, 컷별 사운드 이벤트 추론, 트랙 병합의 세 단계로 구성된 비디오 분석 파이프라인을 제안한다. 오디오 생성 모델에 활용 가능한 구조화된 멀티트랙 메타데이터를 산출함으로써, 멀티트랙 사운드 디자인 및 데이터셋 구축의 기반을 제시한다.

1. 서 론

최근 생성형 AI는 오디오 생성과 사운드 디자인 분야로 빠르게 확장되고 있다. 특히 비디오에 적합한 사운드를 생성하는 연구가 활발히 진행되고 있으나, 현행 방법들은 모든 사운드가 하나로 혼합된 싱글트랙 오디오를 생성하는데 그쳐 실제 사운드 디자인 환경에서 요구되는 멀티트랙 기반 편집 워크플로우와 괴리를 보인다. 실제 현업에서는 인물의 움직임, 물체 충돌, 의상 마찰, 배경음 등을 개별 트랙으로 생성한 뒤, 각 트랙의 볼륨, 타이밍, 공간감을 독립적으로 조정하는 과정이 필수적이다.

본 연구는 멀티트랙 사운드 생성을 위한 구조화된 중간 표현을 생성하는 것을 목표로 한다. 주요 기여는 다음과 같다. (1) 멀티트랙 오디오 생성을 위한 메타데이터 구조를 정의한다. (2) 전역 비디오 분석, 컷 단위 이벤트 추론, 트랙 병합으로 구성된 파이프라인을 설계하여 정밀한 이벤트 추적과 동일 이벤트의 사운드 일관성을 보장하는데 기여한다. (3) Vision Language Model(VLM)을 활용하여 파이프라인을 자동화함으로써 향후 멀티트랙 오디오 생성 및 데이터 셋 구축의 기반을 제시한다.

2. 관련 연구

FoleyCrafter[1]는 Text-to-Audio(T2A) 모델을 기반으로 의미적 정합을 위한 semantic adapter와 정밀한 오디오-비디오 동기화를 위한 temporal controller를 결합하여 비디오와 시각적으로 정렬된 효과음을 생성한다. MMAudio[2]는 멀티모달 공동 학습 방식과 조건부 동기화 모듈을 도입한 Video-to-Audio(V2A) 모델로 비디오와 동기화된 오디오를 생성한다. 그러나 두 방법 모두 영상 전체에 대응되는 단일 오디오 waveform을 생성하는 한계가 있다.

멀티트랙 방식을 시도한 연구도 존재한다. SoundStager[3]는 비디오의 특징을 분석하여 멀티트랙 오디오를 자동으로 생성한다. VARCO Sound[4]는 영상 속 여러 사운드 요소를 개별 트랙으로 생성함으로써 트랙별 조정을 지원한다. 그러나 두 방법 모두 여러 컷에 걸쳐 반복되는 동일한 이벤트를 하나의 일관된 트랙으로 병합하는 작업은 다루지 않아, 동일한 사운드 이벤트임에도 위치에 따라 상이한 오디오가 생성되는 문제가 존재한다.

3. 진행 방법론

3.1 데이터 수집 및 전처리

본 실험에서는 세 가지 난이도를 가진 영상을 활용하였다. VGGsound[5]에서 클립을 두 개 가져온 뒤, a-b-a-b 형식으로 교차 배치하여 트랙 병합을 테스트하기 용이하게 구성하였다. 난이도 별 5개의 영상을 생성하였으며 난이도 하 영상은 상이한 클래스로 구성된 반면, 난이도 중 영상은 동일한 클래스의 유사한 클립들로 구성하여 분석 난이도를 높이고자 하였다. 난이도 상 영상은 실제 상용 서비스 환경을 가정하여 공개된 애니메이션 및 영화 클립을 활용하였다. 모든 영상은 오디오를 제거하여 실제 추론과 동일한 환경을 설정하였다. 영상 선정 기준은 (1) 명확한 물체 간 상호작용, (2) 다수의 소리 발생원 존재, (3) 다양한 음향 특성(충격음-지속음-배경음)의 존재이다.

3.2 파이프라인

3.2.1 플로우차트




그림 1 파이프라인 플로우차트

3.2.2 각 Stage 기능 및 입출력 설명

Stage 01. 영상 컷 분할

영상이 길어질수록 VLM의 비디오 분석 품질이 저하되는 것을 방지하기 위해 영상을 컷 단위로 분할하는 작업을 거친다. 표 2와 같이 반복 실험 결과, VLM은 실행 회차마다 컷 수가 달라지는 불안정한 모습을 보인 반면, 컷 전환을 감지하는 파이썬 라이브러리인 PySceneDetect는 안정적인 결과를 보였다. 의미적 분할 성능에서도 VLM 대비 유의미한 차이가 관찰되지 않았으며, 평균 컷 수도 유사한 경향을 보였다. 안정성 확보를 위해 PySceneDetect를 채택하였다.

영상	분할된 컷 개수 (1/2/3차 반복 결과)	
	PySceneDetect	Gemini 2.5 pro
1	4 / 4 / 4	4 / 6 / 6
2	8 / 8 / 8	8 / 4 / 4
3	14 / 14 / 14	10 / 12 / 18
4	12 / 12 / 12	11 / 12 / 9
5	6 / 6 / 6	5 / 6 / 6

표 1 PySceneDetect vs. Gemini 2.5 pro 컷 분할 변동 비교

Stage 02. 영상 업로드

Gemini File API로 타겟 영상을 업로드한다.

Stage 03. 전역 영상 분석 및 사운드 소스 레지스트리 구축

영상에 등장하는 시각적 사운드 소스를 식별하여 사운드 소스를 Entity, Entity Child, Ambience로 분류하여 사운드 소스 레지스트리(EntityRegistry)로 구조화한다. 각 컷별로 등장하는 소스를 기록한 컷-소스 매핑 정보(cut_mapping)를 생성한다. Entity는 기본 사운드 소스이며, 하위에 Entity Child를 둘 수 있다. Entity Child는 동일한 상위 Entity에 속하더라도 음향적으로 독립된 사운드를 생성한다고 판단되는 경우에만 분리한다. 예를 들어 인물이 착용한 장비와 손에 든 물체가 서로 다른 사운드를 유발하는 것으로 판단되면, 장비와 물체는 해당 인물을 상위 Entity로 삼는 별도의 Child로 분리된다. Ambience는 배경음을 나타내며, 배경에 등장하는 개별 사물들에 의해 과분할되는 것을 방지하기 위해 Child를 두지 않도록 설정하였다. EntityRegistry와 cut_mapping은 후속 단계에서 기준으로 활용되어 일관적이고 안정적인 분석을 돕는다.

Stage 04. 컷별 클립 생성

Stage 01의 컷 경계 정보에 맞게 각 컷에 해당하는 클립을 생성한다. 분석 범위를 좁히고 장면에 존재하지 않는 정보가 생성되는 것을 방지한다.

Stage 05. 컷별 사운드 이벤트 추론

영상에서 발생 가능한 사운드 이벤트를 추론한다. Stage 03에서 생성된 cut_mapping을 함께 제공받아 컷에 등장하는 소스 정보를 참조함으로써 소스 누락을 완화한다.

표 3과 같이 각 사운드 이벤트에 대해 <사운드 소스, 사운드 유형, 이벤트 타입, 타임스탬프, Sound Description>를 생성한다.

사운드 소스	사운드 유형	이벤트 타입	타임스탬프	Sound Description
유발 소스	sfx /ambience	onset /continuous	발생 시간	사운드 묘사

표 2 사운드 이벤트 출력 구조

Stage 06. 사운드 병합 및 최종 트랙 메타데이터 생성

동일한 트랙으로 생성 가능한 사운드 후보를 묶어 최종 트랙을 생성한다. <사운드 소스, 사운드 유형, 이벤트 타입> 세 항목이 모두 동일한 이벤트를 대상으로 1차 병합을 진행한다. 1차 병합 결과 내에 서로 다른 Sound Description이 존재하는 경우 Gemini Flash 기반의 TrackJudge를 호출하여 트랙 분리 여부를 판별한다.

TrackJudge는 사운드의 물리적 메커니즘이 명확히 다른 경우에만 별도 트랙으로 분리한다. 예를 들어 갑옷의 흔들림·빠격임·마찰음은 동일한 착용 이동 메커니즘으로 간주하여 하나의 트랙을 유지하는 반면, 검이 허공을 가르는 소리와 다른 검과의 마찰음은 서로 다른 사운드 메커니즘으로 판단하여 분리한다.

최종 출력은 표 4와 같은 멀티트랙 메타데이터이다. 각 트랙은 독립적인 오디오 생성 단위로 기능하며, 오디오 생성 모델을 통해 트랙별 Sound Description을 통해 오디오를 개별 생성한 뒤 타임스탬프에 맞게 배치함으로써 멀티트랙 오디오 생성이 가능하다.

Track ID	사운드 소스	사운드 유형	이벤트 타입	타임스탬프	Sound Description
----------	--------	--------	--------	-------	-------------------

표 3 멀티트랙 메타데이터 구조

3.3 실험 결과

3.3.1 멀티트랙 메타데이터 생성 결과

VGGsound 샘플에 대한 실험 결과, 영상은 6개의 컷으로 분할되었다. 104개의 사운드 이벤트가 추출되었고 최종 11개의 트랙으로 병합되어 멀티트랙 메타데이터가 생성되었다. 이는 본 파이프라인이 영상 내용을 단순 나열하는 것이 아닌 멀티트랙 오디오 생성을 위한 구조적 메타데이터를 생성할 수 있음을 보여준다. 그림 3은 샘플 영상에 대해 생성된 메타데이터를 시각화하여 배치한 것이며, 표 5, 6은 메타데이터 생성 결과이다.



그림 2 VGGsound 타겟 영상 샘플




그림 3 메타데이터 시각화 결과

Track ID	사운드 소스	사운드 유형	이벤트 타입	타임스탬프
Track 01	boy_cloth	sfx	continuous	0.0~5.0s, 10.0~15.0s
Track 03	ping_pong_ball	sfx	onset	0.5s, 0.9s, ...
Track 05	ping_pong_table	sfx	onset	6.9s, 7.3s, ...
Track 11	indoor_room	ambience	continuous	0.0~5.0s, 10s~15s

표 4 멀티트랙 메타데이터 생성 결과

ID	Sound Description
Track 01	Subtle rustle of a cotton sweatshirt during movement
Track 03	Quick, sharp bounce of a ping pong ball on a hard wooden table
Track 05	The crisp, hollow sound of a ping pong ball bouncing on the table
Track 11	Quiet indoor room tone of a dinig area

표 5 각 트랙에 대한 Description 결과

3.3.2 실험 통계

난이도	영상 수	Entities	Sound event	Track
하	5	7.2	25.4	7.2
중	5	7.2	26.0	5.0
상	5	11.0	43.2	16.0

표 6 난이도 별 영상 실험 결과

전체 실험 결과, 영상당 평균 30개의 사운드 이벤트가 추출되어 약 10개의 트랙으로 병합되었다. 이벤트 대비 최종 트랙 수의 비율은 약 3:1로, 컷 전환에 걸쳐 반복되는 동일한 사운드 이벤트가 트랙으로 통합됨을 확인할 수 있다.

4. 비교실험

4.1 멀티트랙 V2A 상용 서비스와의 비교

상용서비스인 VARCO Sound[4]와 비교실험을 수행하였다. 본 논문의 기법은 두 가지 측면에서 구조적 차별성을 가진다. (1) 여러 컷에 흩어진 반복 사운드를 단일 트랙으로 병합하여 시간적 일관성 보장이 가능하다. (2) 조건부 모델 라우팅을 통한 비디오-오디오 시간 정렬에 기여할 수 있다.

VARCO Sound로 대표되는 멀티트랙 V2A 서비스는 시간 간격을 두고 반복되는 동일한 사운드를 개별 이벤트로 기록하여 생성 시점마다 사운드가 상이해지고 시간적 일관성이 훼손된다. 본 논문의 파이프라인은 EntityRegistry 기반 전역 분석을 기반삼아 분산된 동일 사운드를 단일 트랙으로 병합함으로써 시간적 일관성을 확보할 수 있다.




그림 4 VARCO Sound와 제안 기법의 최종 생성 트랙 비교

VARCO Sound는 T2A 단일 구조를 채택하기 때문에, 타격음처럼 시각적 타이밍이 중요한 이벤트에서 비디오-오디오 간 시간적 정렬(AV-sync)이 틀어지는 문제가 발생한다. 본 파이프라인은 메타데이터에 기록되는 이벤트 특성에 따라 T2A 모델과 V2A 모델을 선택적으로 분기하는 라우팅 전략을 적용할 수 있으며, 이를 통해 T2A 기반의 고품질 분리 오디오 생성과 V2A 기반의 시간적 정렬 오디오 생성을 함께 지원 가능하다.




그림 5 V2A 파이프라인 비교

4.2 EntityRegistry 유무에 따른 Ablation Study

표 8은 사운드 소스 레지스트리 구축 없이 description 유사를 기반으로 트랙 병합을 수행하는 방식(w/o Registry)과, 현재 파이프라인(w/ Registry)을 실제 애니메이션 영상 대상으로 비교한 것이다.

run	감지된 사운드 이벤트 수		최종 생성 트랙 개수	
	w/o Registry	w/ Registry	w/o Registry	w/ Registry
1	17	76	8	19
2	10	71	5	21
3	13	71	6	19
평균	13.3	72.7	6.3	19.7
표준편차	3.51	2.87	1.53	1.15

표 7 레지스트리 유무에 따른 파이프라인 결과 비교

w/o Registry는 평균 13.3($\sigma=3.51$)개 이벤트, 6.3개 트랙인 반면, w/ Registry는 평균 72.7($\sigma=2.87$)개 이벤트, 19.7개 트랙으로 레지스트리 기반 소스 구조화가 이벤트 식별을 세분화하고 추론 일관성을 높임을 확인할 수 있다.

5. 결론

5.1 기대효과

본 연구에서 정의하는 멀티트랙 메타데이터는 멀티트랙 오디오 생성의 기반을 제공한다. 각 트랙을 독립적으로 생성할 수 있어 트랙별 조정이 가능하고, 동일 소스의 이벤트는 컷 위치에 관계없이 하나의 트랙으로 병합되어 일관성 있는 오디오 생성이 가능하다. 오디오 생성의 입력 단위를 영상 전체에서 트랙 단위로 분해함으로써 기존 방법이 해결하지 못한 멀티트랙 생성과 편집의 구조적 기반을 제공한다. 이는 향후 멀티트랙 캡션 데이터 구축 및 자동 사운드 디자인 파이프라인의 기반으로 활용할 수 있다.

5.2 한계점 및 향후 연구 방안

본 연구는 관련 평가 지표의 부재로 정량적 성능 검증이 미흡하고, VLM 기반 추론의 확률적 특성으로 인해 추론 회차 간 일관성이 완벽히 보장되지 않는다는 한계가 존재한다. 향후에는 정량적 평가 기준 및 인간 평가 시스템을 도입하고, 결정론적 분석도구를 활용하여 VLM 의존도를 줄임으로써 안정적인 자동화 파이프라인을 구현할 수 있을 것으로 기대된다.

6. 참고문헌

- [1] Y. Zhang et al., "Foleycrafter: Bring silent videos to life with lifelike and synchronized sounds," Int. J. Comput. Vis., vol. 134, no. 1, p. 46, 2026.
- [2] H. K. Cheng, M. Ishii, A. Hayakawa, T. Shibuya, A. Schwing, and Y. Mitsufuji, "Mmaudio: Taming multimodal joint training for high-quality video-to-audio synthesis," Proc. CVPR, pp. 28901-28911, 2025.
- [3] S. Yoo, A. Hernandez Santisteban, P. Seetharaman, J. Salamon, O. Nieto, and A. Truong, "SoundStager: Interactive Design of Story-Driven GenAI Soundscapes for Video," Proc. CHI, pp. 1-26, 2026.
- [4] NC AI, "VARCO Sound," [Online]. Available: <https://sound.varco.ai>. [Accessed: Apr. 2026].
- [5] H. Chen, W. Xie, A. Vedaldi, and A. Zisserman, "Vggsound: A large-scale audio-visual dataset," Proc. ICASSP, pp. 721-725, 2020.

* 본 연구는 2026년 과학기술정보통신부 및 정보통신기획평가원의 AI중심대학사업(2026-0-00036)과 멀티모달 AI에이전트 시대에 적합한 실무형 AI인재육성프로그램(RS-2025-25441313)의 지원을 받아 수행되었음

o 본 연구의 저자들은 이 연구에 동등하게 기여함

** 교신저자: 장두성