

흉부 X-선 판독 보조 모델의 임상 배치 준비도 평가: 신뢰성 세 차원 기반 교차 점검 프레임워크*

신영원¹ 차수환¹ 이승현¹ 이택훈¹ 윤찬민¹ 정영민²

¹ 서강대학교 컴퓨터공학과 ² 서강대학교 융합교육원 AI·SW 교육센터
{shinforever12, dndoehrk11, i2006307, brachiosaurus19, jsibysh777}@gmail.com, ymchung@sogang.ac.kr

Clinical Deployment-Readiness Evaluation of Chest X-ray CAD Models: A Cross-Checking Framework Based on Three Reliability Dimensions

Yeongwon Shin¹ Suhwan Tcha¹ Seunghyun Lee¹ Taekhun Lee¹ Chanmin Yoon¹ Youngmin Chung²

¹ Department of Computer Science and Engineering, Sogang University

² AI·SW Education Center, Sogang Institute for Convergence Education

요약

흉부 X-선 판독 보조(CXR-CAD) 모델은 높은 평균 AUROC를 보이더라도 실제 임상 배치 단계에서는 예측 확률의 불안정성, 외부 데이터셋에서의 성능 저하, 비의학적 단서 의존과 같은 신뢰성 문제가 발생할 수 있다. 본 연구는 이러한 한계를 보완하기 위해 CXR-CAD 모델의 임상 배치 준비도를 확률 보정성, 도메인 변화 강건성, 판단 근거 위치 일관성의 세 차원에서 교차 점검하는 평가 프레임워크를 제안한다. 교차 점검 프레임워크는 각 차원의 평가 결과를 판정 보조 지표에 따라 위험 신호로 해석하고 우선 조치를 제시하는 일련의 절차를 의미하며, 이를 실무적 절차에 연결하기 위하여 배치 준비도 점검 대시보드를 구현하였다. DenseNet, EfficientNet, ViT 기반 모델을 대상으로 진행된 실험 결과, 평균 성능만으로는 드러나지 않는 모델별 신뢰성 위험이 확인되었다. 이는 CXR-CAD 모델의 실제 배치 판단에는 단일 성능 지표가 아니라, 신뢰성 세 차원 기반 교차 점검 절차가 필요함을 보여준다.

1. 서론

CXR-CAD 모델은 높은 평균 AUROC를 달성하더라도 실제 임상 배치 단계에서 신뢰성 문제가 발생할 수 있다. 예측 확률이 해당 확률 구간의 실제 양성률을 제대로 반영하지 못하면 운영 임계값 설정이 불안정해지고, 모델이 촬영 구도, 마커, 배경 음영 등 비병변 단서에 의존하면 내부 검증 성능이 높더라도 판단 근거를 신뢰하기 어렵다. 또한 외부 기관 데이터나 하위 집단 조건에서 성능이 유지되는지 확인하지 않으면 실제 임상 배치 가능성을 판단하기 어렵다.

본 연구는 이러한 한계를 보완하기 위해 CXR-CAD 모델의 임상 배치 준비도를 확률 보정성, 도메인 변화 강건성, 판단 근거 위치 일관성의 세 차원에서 평가하고, 판정 보조 지표 기반 위험 신호와 우선 조치 제시 절차로 연결하는 교차 점검 프레임워크를 제안한다. 또한, 배치 준비도 점검 대시보드를 제시하여 제안 프레임워크가 실제 임상 배치 전 검토 절차에 활용될 수 있음을 보인다.

2. 관련 연구

흉부 X-선 판독 보조 연구는 CheXpert[1]와 같은 공개 데이터셋을 기반으로 DenseNet[2], EfficientNet[3], Transformer (ViT)[4] 등의 모델 구조를 적용하며 AUROC 중심의 성능 향상에 초점을 두어 왔다. 이러한 연구는 질환 분류 성능을 정량적으로 비교하는 데 유용하지만, 평균 AUROC가 높더라도 예측 확률의 신뢰성, 판단 근거의 임상적 타당성, 외부 데이터 및 하위 집단 조건에서의 성능 유지 여부를 충분히 설명하지 못한다.

이를 보완하기 위해 Focal Loss[5]와 같은 불균형 완화 기법, Grad-CAM[6] 기반 설명 가능성 분석, Temperature Scaling[7]과 같은 확률 보정 기법이 활용되어 왔다. 그러나 이들 방법은 주로 개별 성능 개선 또는 사후 분석 도구로 사용되었으며,

확률 보정성, 도메인 변화 강건성, 판단 근거 위치 일관성을 배치 전 의사결정 절차로 함께 해석하는 기준은 제한적이었다.

이에 본 연구는 확률 보정성, 도메인 변화 강건성, 판단 근거 위치 일관성의 세 차원에서 CXR-CAD 모델을 평가하고, 판정 보조 지표에 따라 위험 신호와 우선 조치를 도출하는 절차를 교차 점검 프레임워크로 정의한다. 또한, 이 프레임워크를 실제 배치 전 검토 절차와 연결하기 위해 종합 판정, 차원별 위험 신호, 권고 조치를 제시하는 배치 준비도 점검 대시보드를 구현하였다.

3. 신뢰성 세 차원 기반 교차 점검 프레임워크 및 구현

본 연구에서 제안하는 교차 점검 프레임워크는 세 신뢰성 차원별 점검 지표를 산출하고, 이를 판정 보조 지표에 따라 양호 또는 주의로 판정한 뒤, 주의 항목을 배치 전 위험 신호로 해석하여 우선 조치를 제시하는 절차를 의미한다.

3.1 신뢰성 세 차원과 점검 지표

제안 프레임워크는 임상 배치 이전에 모델을 서로 다른 배치 실패 가능성을 포착하는 세 가지 신뢰성 차원에서 점검한다. 첫째, 확률 보정성은 ECE(Expected Calibration Error)를 통해 예측 확률과 실제 양성 비율의 일치 여부를 확인하며, 이는 예측 확률이 실제 양성 비율과 잘 일치할수록 특정 확률 이상을 양성 판정 또는 경고 대상으로 분류하는 기준값을 신뢰성 있게 설정할 수 있으므로 관련된다. 둘째, 도메인 변화 강건성은 Subgroup AUROC gap(하위 집단 AUROC 편차) 및 External AUROC drop(외부 데이터셋 AUROC 하락)을 점검하며, 이는 데이터 분포 변화에 대한 일반화 가능성을 평가한다. 셋째, 판단 근거 위치 일관성은 Grad-CAM 기반 분석을 통해 모델이 병변 영역이 아닌 비의학적 단서에 의존하는지를 Shortcut ratio(지름길 학습 비율)와 Localization overlap(판단 근거 위치 겹침도)을 통해 확인한다. 이는 예측 근거의 임상적 타당성과 연결된다. 이처럼 세 차원은 확률값의 신뢰성, 데이터 분포 변화에 대한 안정성, 판단 근거의 타당성이라는 서로 다른 배치 위험을 나누어

점검한다. 따라서 한 차원에서 양호한 결과가 다른 차원의 신뢰성을 보장하지 않으며, 실제 배치 판단에서는 세 차원의 교차 해석이 필요하다.

3.2 세 차원별 결과의 위험 신호 해석을 위한 판정 보조 기준표

교차 점검 프레임워크의 첫 단계는 모델을 확률 보정성, 도메인 변화 강건성, 판단 근거 위치 일관성의 세 차원에서 점검하는 것이며, 다음 단계는 각 지표값을 판정 보조 기준표에 따라 배치 전 위험 신호로 해석하고, 이를 우선 조치로 연결하는 것이다. 이에 본 연구는 세 차원의 평가 결과를 배치 가능성 판단과 후속 조치 제안으로 연결하기 위한 판정 보조 기준표를 제시한다.

표 1. 배치 준비도 점검을 위한 판정 보조 기준표

신뢰성 차원	점검 지표	양호	주의	우선 조치
확률 보정성	ECE	$ECE < 0.05$	$ECE \geq 0.05$	Temperature Scaling 재보정
판단 근거 위치 일관성	Localization overlap, Shortcut ratio	$overlap \geq 0.5$, ratio $< 5\%$	$overlap < 0.5$ 또는 ratio $\geq 5\%$	학습 데이터 정제, ROI 기반 재학습
도메인 변화 강건성	하위 집단 AUROC 편차, 외부 데이터셋 AUROC 하락	편차 $< 3\%p$, 하락 $< 3\%p$	편차 $\geq 3\%p$ 또는 하락 $\geq 3\%p$	하위 집단 재학습, 기관별 미세 조정

이 기준은 절대적 승인 규칙이 아니라, 각 차원에서 식별된 위험 신호를 배치 전 재검토와 우선 조치로 연결하기 위한 보조 기준이다. 본 연구에서는 이를 배치 준비도 점검 대시보드에 반영하여, 사용자가 점검 지표의 위험 판정 임계값을 직접 조정하고 그 결과에 따른 종합 배치 판정과 세부 위험 이슈를 확인할 수 있도록 구현하였다.

3.3 교차 점검 프레임워크의 대시보드 구현




그림 1. 배치 준비도 점검 대시보드의 종합 판정 및 핵심 신뢰성 지표 요약

그림 1은 사용자가 설정한 위험 임계값을 기준으로 모델의 배치 준비도를 종합 판정한 화면이다. ECE, Shortcut ratio, External AUROC drop(외부 데이터셋 AUROC 하락) 등의 핵심 지표를 함께 제시하며, 기준 초과 항목이 존재할 경우 배치 보류 또는 재검토 권고로 연결된다.

dimension	severity	message	recommended_action
calibration	warning	$ECE=0.133 \geq 0.075$	Temperature scaling 재보정 및 운영 임계점 재설정
domain_robustness	warning	Subgroup AUROC gap=4.2pp	취약 취약집단 보강, reweighting, subgroup validation 추가
domain_robustness	critical	External AUROC drop=4.3pp	외부기관 fine-tuning/domain adaptation 전 배치 보류
localization	warning	Shortcut pattern ratio=13.0%	shortcut-prone sample 정제 및 ROI 기반 검증 추가

그림 2. 배치 준비도 점검 대시보드의 신뢰성 차원별 판정 기준에 따른 배치 준비도 이슈 및 권고 조치 요약

그림 2는 세 신뢰성 차원의 평가 결과를 판정 보조 기준표와 연결하여, 각 차원에서 탐지된 위험 신호와 권고 조치를 함께 제시한 화면이다. 대시보드에서는 화면 구성상 확률 보정성을 calibration, 도메인 변화 강건성을 domain robustness, 판단 근거 위치 일관성을 localization 으로 축약 표기하였다. 예를 들어 ECE가 기준을 초과하면 확률 보정이 필요한 신호로, Subgroup AUROC gap 또는 External AUROC drop이 큰 경우 도메인 변화 강건성의 위험 신호로, Shortcut ratio가 높은 경우 판단 근거 위치 일관성의 위험 신호로 표시된다.

4. 실험 결과 및 프레임워크 검증

4.1 실험 설계 및 평가 지표

본 장에서는 NIH ChestX-ray14 기반으로 학습한 DenseNet, EfficientNet, ViT 기반 CXR-CAD 모델을 대상으로, 3.1 절에서 제시한 세 신뢰성 차원의 점검 지표를 산출하였다. 데이터 누수를 줄이기 위해 환자 단위 분할을 적용하고, 학습 과정에서는 5-fold GroupKFold 검증을 사용하였다. 내부 성능은 NIH 테스트셋에서, 외부 데이터셋 성능은 CheXpert의 공통 질환 7개 항목에서 평가하였다. 하위 집단 분석은 성별, 연령대, 촬영 구도(PA/AP)를 기준으로 수행하였으며, Grad-CAM 분석은 활성화 영역이 폐 또는 병변 관심 영역에 위치하는지와 마커, 골격, 의료기기, 영상 가장자리 등 비병변 단서에 집중되는지를 기준으로 판정하였다.

확률 보정성은 ECE를, 도메인 변화 강건성은 External AUROC drop과 Subgroup AUROC gap을, 판단 근거 위치 일관성은 Shortcut ratio와 Localization overlap을 측정하였다. Shortcut ratio는 Grad-CAM에서 지름길 학습 패턴이 관찰된 비율로 정의한다.

$$Shortcut\ ratio = \frac{N_{Shortcut}}{N_{total}} \times 100 \quad (1)$$

여기서 $N_{Shortcut}$ 은 비병변 단서에 활성화가 집중된 사례 수이며, N_{total} 은 전체 Grad-CAM 분석 사례 수이다. 값이 높을수록 모델이 비병변 단서에 의존할 가능성이 크다.

Localization overlap은 모델의 활성화 영역과 기준 병변 영역 또는 해부학적 관심 영역의 겹침 정도로 정의하며, IoU를 사용한다.

$$Localization\ overlap = \frac{|A \cap R|}{|A \cup R|} \quad (2)$$

여기서 A는 Grad-CAM에서 활성화된 영역, R은 기준 병변 또는 관심 영역이다. 이 값은 0에서 1 사이의 단위 없는 값이며, 클수록 모델의 판단 근거가 의학적으로 타당한 위치와 잘 일치함을 의미한다. 본 실험은 평균 AUROC가 유사하게 높더라도 세 신뢰성 차원에서는 서로 다른 위험 양상이 나타날 수 있음을 확인하고, 이를 배치 가능성 판단과 우선 조치 제안으로 연결하기 위해 수행하였다.

4.2 신뢰성 세 차원 평가 결과와 교차 해석 필요성

세 신뢰성 차원 평가에 앞서 세 모델의 기본 분류 성능을 확인한 결과, DenseNet, EfficientNet, ViT의 평균 AUROC는 각각 0.8667, 0.8538, 0.8703으로 나타났다. 세 모델 모두 0.85 이상의 구분 성능을 보였으나, 평균 AUROC는 양성과 음성을 구분하는 능력을 나타낼 뿐, 예측 확률의 보정 정도, 외부 데이터에서의 성능 안정성, 판단 근거의 위치적 타당성을 직접 설명하지 못한다.

신뢰성 차원	핵심 지표	DenseNet	EfficientNet	ViT
확률 보정성	ECE	0.041	0.058	0.072
도메인 변화 강건성	External AUROC drop (%)	4.3%p	5.1%p	2.8%p
	Subgroup AUROC gap (%)	4.2%p	3.6%p	2.9%p
판단 근거 위치 일관성	Shortcut ratio (%)	13.0%	10.4%	8.7%
	Localization overlap (IoU)	0.42	0.47	0.51

그림 3. 세 모델의 신뢰성 평가 요약

그림 3은 세 모델의 신뢰성 세 차원 평가 결과를 나타낸다. 확률 보정성에서는 DenseNet 이 ECE 0.041 로 가장 낮아 가장 안정적인 예측 확률을 보였고, EfficientNet 은 0.058, ViT 는 0.072 로 나타났다. 반면 도메인 변화 강건성에서는 ViT 가 External AUROC drop 2.8%p, Subgroup AUROC gap 2.9%p 로 가장 낮은 값을 보여 외부 데이터 및 하위 집단 변화에 상대적으로 안정적이었다. 판단 근거 위치 일관성에서도 ViT 는 세 모델 중 Shortcut ratio 가 상대적으로 낮고 Localization overlap 이 높게 나타나, 비교 대상 모델들에 비해 판단 근거가 의학적 타당한 위치에 형성되는 경향을 보였다.

이 결과는 신뢰성 세 차원이 모델별로 서로 다른 위험 양상을 분리해 드러내며, 서로 다른 배치 위험을 포착하는 평가 차원임을 보여준다. DenseNet 은 확률 보정성 지표에서 상대적으로 우수한 값을 보였으나, 도메인 변화와 판단 근거 위치 일관성 측면에서는 상대적으로 취약한 경향을 보였다. 반면 ViT 는 평균 AUROC, 도메인 변화 강건성, 판단 근거 위치 일관성 지표에서는 상대적으로 우수한 경향을 보였지만, ECE 는 가장 높게 나타났다.

따라서 CXR-CAD 모델의 임상 배치 가능성은 평균 AUROC 만으로 판단하기 어렵고, 확률 보정성, 도메인 변화 강건성, 판단 근거 위치 일관성을 함께 고려하는 교차 해석이 필요하다.

4.3 교차 점검 프레임워크 기반 배치 준비도 판단

본 절에서는 4.2 절에서 확인한 신뢰성 세 차원 결과를 판정 보조 기준표에 적용하여, 배치 판단과 우선 조치로 변환한다. 4.2 절에서는 신뢰성 세 차원의 평가 결과를 제시하여 평균 AUROC 중심 판단의 한계를 보이고 교차 해석의 필요성을 강조하였다. 본 절은 그 결과를 배치 가능성 판단과 우선 조치 제안의 과정으로 연결함으로써, 교차 점검 프레임워크가 배치 전 의사결정 절차로 작동할 수 있음을 확인한다.

모델	평균 AUROC 기반 배치 판단	교차 점검 프레임워크			우선 조치
		확률 보정성	도메인 변화 강건성	판단 근거 위치 일관성	
DenseNet	양호	양호 (ECE 0.041)	주의 (외부 4.3%p 하위 4.2%p)	주의 (지름길 13.0%)	하위집단 재학습, ROI 기반 재학습
EfficientNet	양호	주의 (ECE 0.058)	주의 (외부 5.1%p 하위 3.6%p)	주의 (지름길 10.4%)	Temperature Scaling, 재학습, 데이터 점검
ViT	양호	주의 (ECE 0.072)	양호 (외부 2.8%p 하위 2.9%p)	주의 (지름길 8.7%)	Temperature Scaling, ROI 기반 재학습

그림 4. 평균 AUROC 기반 배치 판단 대비 교차 점검 프레임워크 기반 배치 판단
그림 4는 표 1의 판정 보조 기준표를 바탕으로 세 신뢰성 차원의 평가 결과를 배치
가능성 판단과 우선 조치로 변환한 결과를 나타낸다.

평균 AUROC 기준만 적용하면 DenseNet, EfficientNet, ViT 모두 양호한 모델로 해석된다. 그러나 교차 점검 프레임워크를 적용하면 각 모델의 위험 양상이 보다 구체적으로 드러난다. DenseNet 은 확률 보정성은 양호하지만 도메인 변화 강건성과

판단 근거 위치 일관성에서 주의가 필요하며, EfficientNet 은 세 차원 모두에서 위험 신호가 확인된다. ViT 역시 평균 AUROC 기반 판단에서는 양호하지만, 확률 보정성과 판단 근거 위치 일관성에서 보완이 필요한 것으로 나타난다. 따라서 제안 프레임워크는 평균 AUROC 중심 판단이 놓칠 수 있는 차원별 위험을 식별하고, 이를 Temperature Scaling, 하위 집단 재학습, ROI 기반 재학습, 데이터 점검과 같은 우선 조치로 연결한다. 이는 교차 점검 프레임워크가 단순 성능 비교를 넘어, 임상 배치 전 위험 신호 해석과 후속 조치 제안으로 이어지는 의사결정 절차로 활용될 수 있음을 보여준다.

5. 결론

본 연구는 CXR-CAD 모델의 임상 배치 가능성을 평균 AUROC 중심의 단일 성능 평가가 아니라, 확률 보정성, 도메인 변화 강건성, 판단 근거 위치 일관성의 세 차원에서 교차 점검하는 프레임워크로 재구성하였다. 실험 결과, 세 모델은 모두 0.85 이상의 평균 AUROC 를 보였으나, 신뢰성 세 차원에서는 서로 다른 위험 양상을 보였다. 이는 평균 성능만으로는 모델의 임상 배치 준비도를 충분히 판단할 수 없음을 보여준다. 따라서 CXR-CAD 모델의 실제 배치 판단에는 단일 지표가 아니라 세 신뢰성 차원의 교차 해석이 필요하다. 본 연구는 이를 위해 지표 산출, 판정 보조 기준표 기반 위험 신호 해석 및 후속 조치 제안을 교차 점검 프레임워크로 통합하여 정의하고, 이를 실무적 절차로 연결하는 배치 준비도 점검 대시보드를 구현하였다. 배치 준비도 점검 대시보드는 종합 배치 판정, 차원별 위험 신호, 우선 조치를 한 화면에서 확인할 수 있도록 하여, 제안 프레임워크를 실제 배치 전 검토 절차로 연결한다는 점에서 의의가 있다.

참고문헌

- [1] J. Irvin et al., "CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison," Proc. AAAI, vol. 33, no. 1, pp. 590-597, 2019.
- [2] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely Connected Convolutional Networks," Proc. CVPR, pp. 4700-4708, 2017.
- [3] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," Proc. ICML, pp. 6105-6114, 2019.
- [4] A. Dosovitskiy et al., "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," Proc. ICLR, 2021.
- [5] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal Loss for Dense Object Detection," Proc. ICCV, pp. 2980-2988, 2017.
- [6] R. R. Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization," Int. J. Comput. Vis., vol. 128, no. 2, pp. 336-359, 2020.
- [7] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On Calibration of Modern Neural Networks," Proc. ICML, pp. 1321-1330, 2017.